

项目名称

AI 辅助舆情分类测试流程搭建

项目目标

验证大语言模型在短文本舆情情感分类中的能力边界，搭建端到端测试流程，量化 Prompt 效果。

技术栈

Python、DeepSeek API、Prompt Engineering、Pandas、Requests

核心流程

text

Excel 评论数据 → Python 脚本 → DeepSeek API → 情感分类 → 对比人工标注 → 准确率统计

- 输入：16 条真实用户评论（含人工标注）
- 处理：调用 API，使用设计的 Prompt 进行分类
- 输出：情感标签 + 准确率 + Bad Case 分析

Prompt 设计

text

判断情感是正面/负面/中性，只回答一个词。

设计原则：

- 输出格式明确（单一词汇）
- temperature = 0（保证结果稳定）
- 可扩展：后续可增加反讽、中性边界等规则

测试结果（16 条真实评论）

指标

数值

指标	数值
总条数	16
正确数	12
错误数	4
准确率	75.0%

Bad Case 分析（被分错的 4 条）

评论内容	正确答案	AI 预测	问题类型
我来拉低中奖率	中性	正面	调侃/自嘲误判为正面

（其他 3 条可根据你的实际输出补充）

💡 说明 AI 在处理“调侃”“中性表达”“隐含情绪”时存在局限

AI 能力边界总结

☒ 擅长

☐ 不擅长/需优化

明确的正负面判断

调侃/自嘲语句（如“拉低中奖率”）

关键词/情绪提取

中性但带有情绪的评论

☑ 擅长

✗ 不擅长/需优化

批量稳定处理

反讽、文化梗、复杂情绪

落地建议

“AI 初筛 + 人工复核 + Bad Case 入库”

- 日常场景（约 75%）：AI 自动分类，提升效率
- 边界场景（约 25%）：人工抽检，保证质量
- 持续迭代：将 Bad Case 加入 Prompt 优化库

项目价值

- 独立完成从 Prompt 设计 → API 调用 → 结果评估的完整流程
- 真实数据测试准确率 75%，明确 AI 能力边界
- 形成可复用的测试框架和优化方法论
- 提出可落地的“AI + 人工” workflows 方案